Parallel Dataloader

Parallel Programming for Machine Learning
Project Work in Artificial Intelligence Programming

Niccolò Arati

28/03/2024

Introduzione

Un Dataloader è una classe che fornisce un modo flessibile ed efficiente per caricare dei dati.
In questo lavoro ci occuperemo di caricare dei batch immagini ed applicare ad esse delle tecniche di data augmentation tra un batch e l'altro.

Sono presenti due implementazioni del Dataloader: una **sequenziale** e una **parallela**. Lo scopo di questo elaborato è quello di osservare lo **speedup** ottenuto con la versione parallela rispetto a quella sequenziale.

Il linguaggio di programmazione utilizzato è Python, usando come IDE PyCharm, e la parallelizzazione è stata eseguita con **Multiprocessing**.
Tutti gli esperimenti sono stati svolti su un PC con Windows 10 come sistema operativo e una CPU Intel Pentium Gold G5400.

Introduzione

Esempio di utilizzo del Dataloader

```
transform1 = albumentations.Compose([
    resize.Resize(height = 256, width = 256, p = 1),
    albumentations.RandomCrop(width = 200, height = 200, p = 1)
])
```

```
dataloader = DataLoader.DataLoader(dataset, batch_size = 300)
startSeq = time.time()
for batch in dataloader:
    for image in batch:
        transformed = transform1(image = image)['image']
endSeq = time.time()
resultSeq1 = endSeq - startSeq
```

Organizzazione del codice

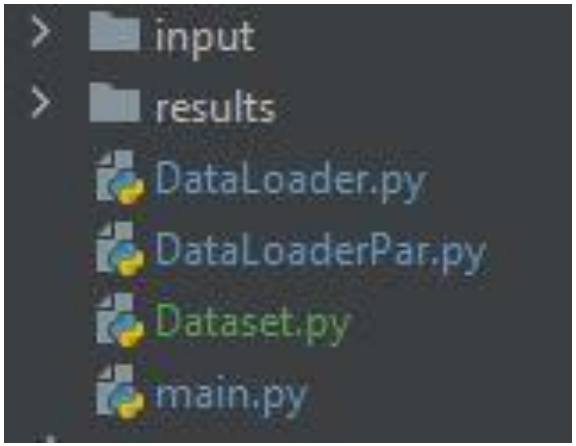

Organizzazione del codice

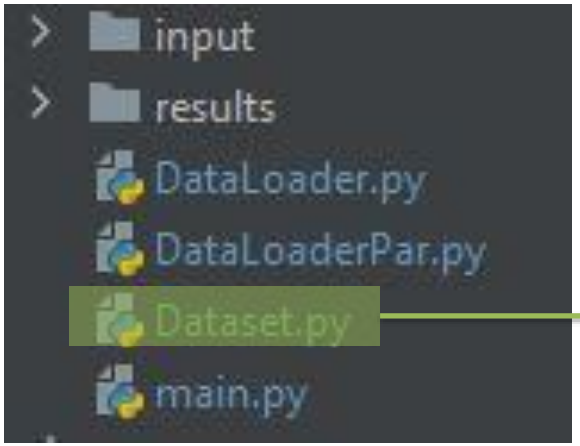

File contenente il codice relativo alla classe Dataset, che serve come wrapper per il dataset effettivo da caricare tramite il Dataloader

Organizzazione del codice

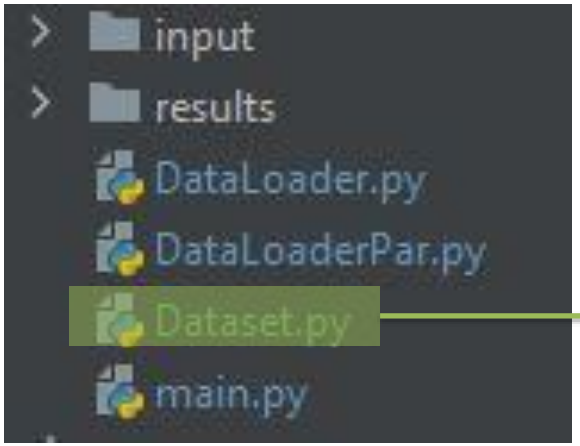


```python
class Dataset:
    def __init__(self, size, im_paths):
        self.size = size
        self.im_paths = im_paths

    def __len__(self):
        return self.size

    def __getitem__(self, index):
        image = cv2.imread(str(self.im_paths[index]))
        image = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)
        return image
```

Organizzazione del codice

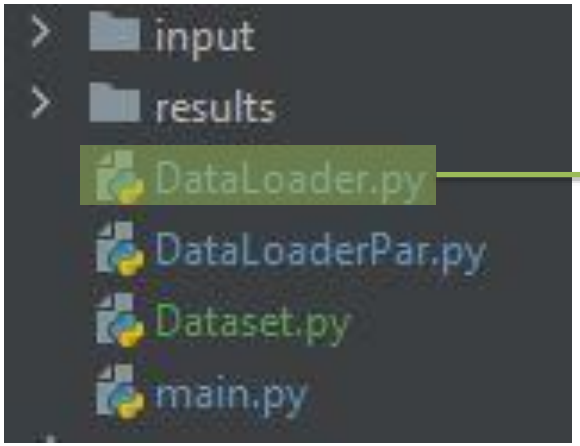

File contenente il codice relativo alla classe DataLoader, che accede al dataset di immagini da caricare e ne restituisce per ogni iterazione un certo numero sotto forma di batch.

Organizzazione del codice

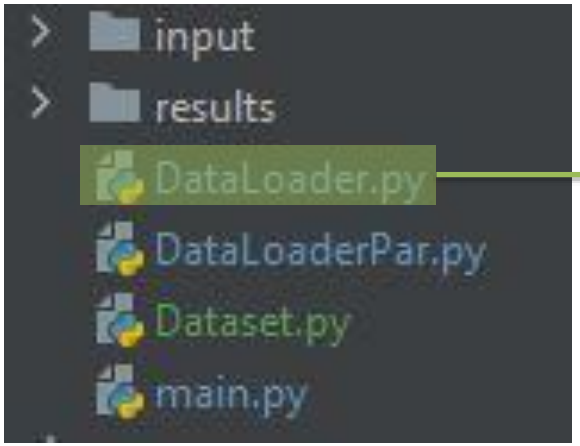


```python
class DataLoader:
    def __init__(self, dataset, batch_size = 1, shuffle = False):
        self.dataset = dataset
        self.batch_size = batch_size
        self.shuffle = shuffle
        self.index = 0 #next index that needs to be loaded

    def __iter__(self):...

    def __next__(self):...

    2 usages (1 dynamic)
    def get(self):...
```

Organizzazione del codice

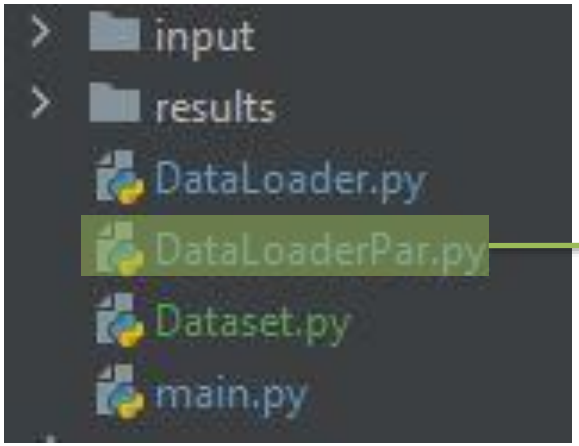

File contenente il codice relativo alla classe DataLoaderPar, sottoclasse di DataLoader che implementa la parallelizzazione del Dataloader.

Organizzazione del codice

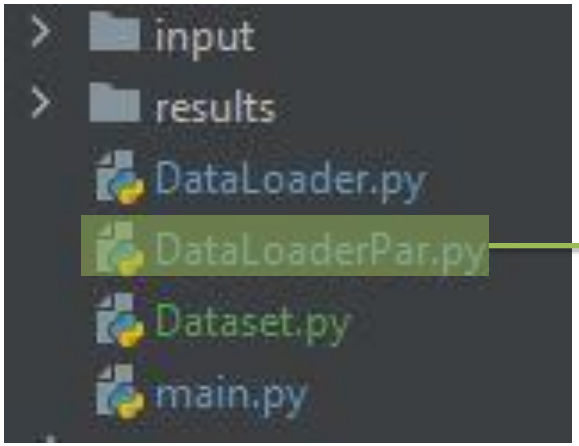


```
def worker_funct(dataset, index_queue, output_queue):...


class DataLoaderPar(DataLoader.DataLoader):
    def __init__(self, dataset, batch_size = 64, shuffle = False,
                 num_workers = 1, prefetch_batches = 2):...

    def prefetch(self):...

    def get(self):...

    def __iter__(self):...

    def __del__(self):...
```

Dataloader Sequenziale

```
def __iter__(self):
    self.index = 0
    return self

def __next__(self):
    if self.index >= len(self.dataset):
        raise StopIteration
    batch_size = min(len(self.dataset) - self.index, self.batch_size)
    batch = tuple([self.get() for _ in range(batch_size)])
    if self.shuffle:
        random.shuffle(batch)
    return batch

def get(self):
    item = self.dataset[self.index]
    self.index += 1
    return item
```

Dataloader Parallelo

Corpo del metodo __init__()

```
super().__init__(dataset, batch_size, shuffle)

self.num_workers = num_workers
self.prefetch_batches = prefetch_batches
self.output_queue = multiprocessing.Queue()
self.index_queues = []
self.workers = []
self.worker_cycle = itertools.cycle(range(num_workers))
self.cache = {}
self.prefetch_index = 0

for _ in range(num_workers):
    index_queue = multiprocessing.Queue()
    worker = multiprocessing.Process(target = worker_funct,
                                     args = (self.dataset, index_queue,
                                             self.output_queue))
    worker.daemon = True
    worker.start()
    self.workers.append(worker)
    self.index_queues.append(index_queue)

self.prefetch()
```

Dataloader Parallelo

Metodo prefetch() e funzione associata ai processi Worker

```
def prefetch(self):
    while (self.prefetch_index < len(self.dataset) and
           self.prefetch_index < self.index + 2 * self.num_workers * self.batch_size):
        # if the prefetch_index hasn't reached the end of the dataset &
        # it is not 2 batches ahead, add indexes to the index queues
        self.index_queues[next(self.worker_cycle)].put(self.prefetch_index) #cycles through workers
        self.prefetch_index += 1
```

```
def worker_funct(dataset, index_queue, output_queue):
    while True:
        try:
            index = index_queue.get(timeout = 0)
        except queue.Empty:
            continue
        if index is None:
            break
        output_queue.put((index, dataset[index]))
```

Dataloader Parallelo

Metodo get()

```
def get(self):
    self.prefetch()
    if self.index in self.cache:
        item = self.cache[self.index]
        del self.cache[self.index]
    else:
        while True:
            try:
                (index, data) = self.output_queue.get(timeout = 0)
            except queue.Empty:
                continue
            if index == self.index:
                item = data
                break
            else:
                self.cache[index] = data
```

Test

Eseguiti su un dataset di 110000 immagini

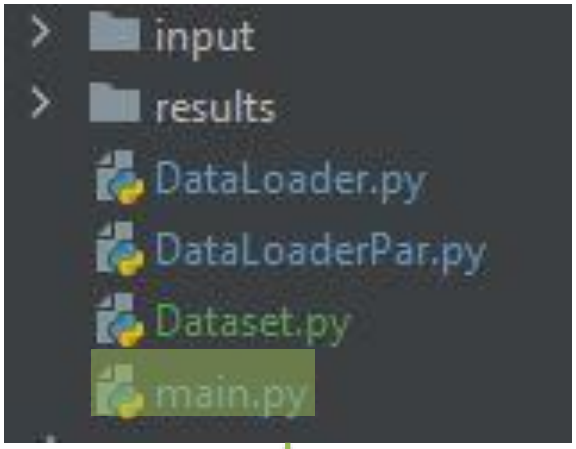


```
#test different number of workers and albumentations with fixed batch_size of 300
def testDataLoaderWT():...


#test different batch sizes with fixed albumentations and num_workers
def testDataLoaderB():...
```

I test si trovano nel file main.py

Test 1

Variare numero di processi Worker e complessità delle trasformazioni applicate alle immagini con Albumentations, con batch_size = 300

	1 worker	2 workers	4 workers	6 workers	8 workers
1° Alb.	1. 03472	1. 38500	1. 87490	2. 14634	1. 9381
2° Alb.	3. 55765	5. 02616	6. 39762	7. 16192	4. 50477
3° Alb.	4. 29092	5. 94258	6. 81652	4. 65382	2. 74523
4° Alb.	4. 52743	6. 68475	5. 05657	3. 58080	2. 15300

Test 2

Variare batch_size con numero di processi Worker pari a 2 e trasformazione fissa delle immagini.

	Speedup
batch_size = 10	1. 54175
batch_size = 50	1. 59989
batch_size = 100	1. 56747
batch_size = 300	1. 55132
batch_size = 500	1. 48342
batch_size = 1000	1. 72745

```
transform = albumentations.Compose([
    resize.Resize(height=256, width=256, p=1),
    albumentations.HorizontalFlip(p=1),
    albumentations.RandomCrop(width=200, height=200, p=1),
    albumentations.RandomBrightnessContrast(p=1),
    albumentations.VerticalFlip(p=1)
])
```