

Parallel Edit Distance

Parallel Programming for Machine Learning

Niccolò Arati

Introduzione

Edit Distance, chiamata anche Distanza di Levenshtein, è una misura di similarità tra due stringhe A e B. Considera numero minimo di **operazioni base** tra caratteri (inserimento, sostituzione, rimozione) da effettuare per trasformare la stringa A nella stringa B.


Si è scelto di valutare ogni operazione di base con lo stesso impatto, infatti ciascuna di esse aumenta di 1 il valore di Edit Distance.


Sono presenti tre implementazioni di Edit Distance **sequenziali** e due implementazioni **parallele**. Lo scopo di questo elaborato è quello di osservare lo **speedup** ottenuto con le versioni parallele rispetto a quelle sequenziali.

Il linguaggio di programmazione utilizzato è il C++ (compilatore MinGW, IDE CLion) e la parallelizzazione è stata svolta con **OpenMP**.


Tutti gli esperimenti sono stati svolti sul server ssh "papavero.dinfo.unifi.it".








File compresi in questo progetto. I restanti sono relativi ad un altro progetto con directory comune.




File contenenti le implementazioni sequenziali di Edit Distance: Full Matrix, Skew Diagonal e Matrix Row.






```
int levenshteinDistFM(const std::string& word1, const std::string& word2, int length1, int length2);
int levenshteinDistSD(const std::string& word1, const std::string& word2, int length1, int length2);
int levenshteinDistMR(const std::string& word1, const std::string& word2, int length1, int length2);
```



File contenenti le due versioni parallelizzate di Edit Distance con approccio Skew Diagonal.

28/03/2024

Organizzazione del codice



Algoritmo Sequenziale: Full Matrix

```
int levenshteinDistFM(const std::string& word1, const std::string& word2, int length1, int length2) {
   int N = length1 + 1;
   std::vector<int> distMatrix( m N * M);
   if (length2 == 0) {
       distMatrix[i] = i;
       distMatrix[j * M] = j;
           int substitutionCost = (word1[i - 1] == word2[j - 1]) ? 0 : 1;
           distMatrix[i * N + j] = std::min(std::min(distMatrix[(i - 1) * M + j] + 1, //deletion cost
                                                distMatrix[i * M + j - 1] + 1), //insertion cost
                                       distMatrix[(i - 1) * M + j - 1] + substitutionCost); //substitution cost
   int result = distMatrix[length1 * N + length2];
   return result:
```

Calcolo matrice di Edit Distance.

Algoritmo Sequenziale: Skew Diagonal

```
int dMIN = 1 - M;
int dMAX = N - 1;
for (int d = dMIN; d <= dMAX; d ++) {
    int iMIN = std::max(d, 1);
    int iMAX = std::min(M + d, N - 1);
    for (int i = iMIN; i <= iMAX; i ++) {
        if (word1[i - 1] != word2[j - 1]) {
            distMatrix[i * N + j] = std::min(std::min(distMatrix[(i - 1) * M + j],
                                                      distMatrix[i * M + j - 1])
                                             distMatrix[(i - 1) * M + j - 1]) + 1;
            distMatrix[i * N + j] = distMatrix[(i - 1) * N + j - 1];
    if (d == -1) {
        d += 2
int result = distMatrix[length1 * N + length2];
return result;
```

```
egin{pmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1m} \ a_{21} & a_{22} & a_{23} & \dots & a_{2m} \ a_{51} & a_{32} & a_{33} & \dots & a_{3m} \ \vdots & \vdots & \vdots & \vdots & \vdots \ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nm} \end{pmatrix}
```

Algoritmo Sequenziale: Matrix Row

```
nt levenshteinDistMR(const std::string& word1, const std::string& word2, int length1, int length2) {
  std::vector<int> prevRow( n: length2 + 1, value 0);
  if (length2 == 0) {
      prevRow[j] = j;
      currRow[0] = i + 1;
          int deletionCost = prevRow[j + 1] + 1;
          int insertionCost = currRow[j] + 1;
          int substitutionCost;
          if (word1[i] == word2[j]) {
              substitutionCost = prevRow[j];
              substitutionCost = prevRow[j] + 1;
  return currRow[length2];
```

Calcolo della i-esima riga della matrice basandosi sulla riga (i-1)esima.

Skew Diagonal Parallelizzato

Una singola parallel overhead


```
for (int d = dMIN; d <= dMAX; d++) {
   int iMIN = std::max(d, 1);
   int iMAX = std::min(M + d, N - 1);
   for (int i = iMIN; i <= iMAX; i++) {
       if (word1[i - 1] != word2[j - 1]) {
           distMatrix[i * N + j] = std::min(std::min(distMatrix[(i - 1) * M + j],
                                                      distMatrix[i * M + j - 1]),
                                             distMatrix[(i - 1) * M + j - 1]) + 1;
       } else {
           distMatrix[i * N + j] = distMatrix[(i - 1) * N + j - 1];
   if (d == -1) {
```

Skew Diagonal Parallelizzato

Multiple parallel overhead

```
for (int d = dMIN; d <= dMAX; d++) {
   int iMIN = std::max(d, 1);
   int iMAX = std::min(M + d, N - 1);
   shared(distMatrix, word1, word2) num_threads(threads)
   for (int i = iMIN; i <= iMAX; i++) {
       if (word1[i - 1] != word2[j - 1]) {
           distMatrix[i * N + j] = std::min(std::min(distMatrix[(i - 1) * M + j],
                                                      distMatrix[i * M + j - 1]),
                                             distMatrix[(i - 1) * M + j - 1]) + 1;
       } else {
           distMatrix[i * N + j] = distMatrix[(i - 1) * N + j - 1];
   if (d == -1) {
```





```
std::string random_string(std::size_t length, int seed) {....}
louble testStringSearchFMTime(const std::string& word1, const std::string& word2, bool repeat) {...}
louble testStringSearchSDTime(const std::string& word1, const std::string& word2, bool repeat) {...}
double testStringSearchMRTime(const std::string& word1, const std::string& word2, bool repeat) {...}
<code>louble testStringSearchSD_OMPTime(const std::string& word1, const std::string& word2, int nThreads, bool repeat) {...}</code>
louble testStringSearchSD_OMP2Time(const std::string& word1, const std::string& word2, int nThreads, bool repeat) {...}
std::vector<double> compareTimeStringSearch(const std::string& word1, const std::string& word2, int nThreads,
                                            bool repeat = true) {...}
ouble compareTimeStringSearchSD(const std::string& word1, const std::string& word2, int nThreads,
```



Confronto tra i vari approcci, 16 threads


	Full Matrix	Skew Diagonal	Matrix Row
P1, len = 5000	3. 2071	3. 70324	2. 31112
P2, len = 5000	2. 85164	3. 29279	2. 05497
P1, len = 15000	3. 3498	5. 15474	2. 43479
P2, len = 15000	3. 18759	4. 90512	2. 31688
P1, len = 28000	3. 63548	6. 48565	2. 58662
P2, len = 28000	3. 52203	6. 28326	2. 5059



Confronto tra i vari approcci, 4 threads

	Full Matrix	Skew Diagonal	Matrix Row
P1, len = 5000	1. 94831	2. 22286	1. 3185
P2, len = 5000	2. 02005	2. 3047	1. 36705
P1, len = 15000	1. 85594	2. 8919	1. 34012
P2, len = 15000	1. 8461	2. 87656	1. 33301
P1, len = 28000	1. 84884	3. 40718	1. 33429
P2, len = 28000	1. 86523	3. 43739	1. 34611

Variare lunghezza delle stringhe, con 8 threads e speedup calcolato tra Full Matrix e Skew Diagonal con singola parallel overhead



Test 3Variare numero di threads, con lunghezza stringhe di 20000

